

ARMDD – Practical Work

Diogo Silva - 1211882

Hugo Ribeiro - 1250520


Introdução.....	1
Arquitetura do Armazém de Dados.....	2
Visão Geral da Arquitetura.....	2
Diagrama Conceptual da Arquitetura.....	4
Requisitos Arquiteturais Específicos.....	4
Justificação da Arquitetura.....	5
Modelo Dimensional.....	7
Objetivo do Modelo Dimensional.....	7
Tabela de Factos.....	7
Dimensões do Modelo.....	8
Data Profiling.....	10
Valores Nulos.....	10
Validação de Domínios.....	10
Integridade referencial.....	10
Deteção de duplicados.....	10
Inconsistências de datas.....	11
Análise estatística e Outliers.....	11
Resultado esperado.....	11

Introdução

Este projeto consiste na concepção e especificação conceptual de um *data mart* destinado à análise histórica das encomendas realizadas na empresa **Plus Orders**, um negócio nacional de comércio eletrónico especializado em moda de luxo, que opera internacionalmente através de diversos **sites por país**.

Todas as encomendas realizadas pelos clientes são centralizadas num sistema operacional (*OLTP*), cujo modelo de dados foi disponibilizado. Este modelo inclui informação sobre clientes, produtos, tamanhos, categorias, países, moedas, sites, encomendas e linhas de

encomenda, entre outras entidades.



O propósito desta primeira entrega é documentar a análise dimensional e definir:

- a **arquitetura global** do armazém de dados;
- o **modelo dimensional** (tabela de factos e dimensões);
- a **granularidade adotada** e as chaves (naturais e substitutas);
- as **estruturas da Staging Area**;
- o **mapeamento** entre sistema operacional → staging → data mart;
- as **estratégias de Slowly Changing Dimensions (SCD)**;
- as **regras de limpeza, deduplicação e transformação** necessárias.

Arquitetura do Armazém de Dados

Visão Geral da Arquitetura

A arquitetura proposta segue o modelo clássico de **Kimball**, baseado numa abordagem *bottom-up*, recorrendo a uma estrutura de *Data Warehouse* em **três camadas**:

Sistema Operacional (OLTP)

Contém os dados transacionais produzidos pelas operações da empresa. Inclui as tabelas:

- Orders,
- OrdersLines,
- OrdersLinesDetails,
- Products,
- Categories,
- Sizes,
- Boxes,
- Sites,

- SitesInfo,
- Currencies,
- Customers,
- Countries,
- ProductsVideos;

Staging Area (STG)

Camada intermédia onde são carregados os dados brutos extraídos do OLTP.

Funções principais:


- Limpeza de dados;
- Verificação de integridade;
- Tratamento de nulos e duplicados;
- Normalização;
- Detecção de inconsistências;
- Armazenamento de registros rejeitados.

Data Mart (camada analítica – OLAP)

Modelo dimensional em **Star Schema**, otimizado para consultas eficientes, composto por:

- *Fact Table*: **Fact_Encomenda**
 - *Dimensões*: Cliente, Produto, Categoria, Tempo, País, Moeda, Site e Envio.
-

Diagrama Conceptual da Arquitetura



Requisitos Arquiteturais Específicos

Cargas incrementais

Em cada execução do ETL, apenas:

- novos registos são inseridos;
- registos existentes são atualizados se sofreram alterações.

Tratamento amplo de qualidade de dados

- Filtragem de registos com erros;
- Armazenamento de registos rejeitados;
- Eliminação de duplicados;
- Normalização de valores (ex.: nomes de países, moedas, categorias).

Conversão monetária

Valores das encomendas estão registados na moeda local do site onde ocorreram.
O Data Mart deve suportar análises:

- na **moeda local**;
- em **EUR**, moeda de uniformização.

Suporte a hierarquias analíticas

- Cliente → País → Zona geográfica
- Produto → Categoria
- Site → País do Site
- Tempo → Ano → Trimestre → Mês → Dia

Alto volume de dados

O *data mart* deve suportar agregações eficientes, especialmente sobre:

- totais mensais;
- análises por cliente;
- análises por site e zona geográfica.

Justificação da Arquitetura

Separação clara entre OLTP e OLAP

Evita impacto no sistema operacional e permite limpeza extensiva dos dados na staging.

Staging Area isolada

Permite:

- executar *data profiling*,
- garantir a consistência,
- identificar erros antes de afetarem o Data Mart.

Modelo Dimensional (Star Schema)

Maximiza desempenho em consultas, especialmente em Power BI.

Conversão monetária controlada

Facilita análises multi-moeda e uniformização em EUR.

SCD Tipo 2 onde necessário

Preserva histórico de atributos críticos, como categoria de produto, país do cliente ou moeda do site.

Modelo Dimensional

Objetivo do Modelo Dimensional

O modelo dimensional definido tem como objetivo facilitar a análise histórica das encomendas da **Plus Orders**, permitindo consultas rápidas, organizadas e fáceis de interpretar em ferramentas como o Power BI. Para isso, recorreu-se à metodologia proposta por **Kimball**, estruturando os dados num **Star Schema** focado no processo de negócio mais importante: a venda de produtos efetuada nos diferentes sites internacionais da empresa.

Tabela de Factos

FactOrderLine	
FactOrderLineKey 	int
DateKey 	int NN
CustomerKey 	int NN
ProductKey 	int NN
CountryKey 	int NN
SiteKey 	int NN
CurrencyKey 	int NN
BoxKey 	int NN
OrderID	int NN
OrderLineID	int NN
Quantity	int
LineTotal	money
Discount	money
PromotionDiscount	money
ShippingCostAllocated	money
TotalLineValue_Local	money
TotalLineValue_EUR	money

A tabela de factos representa a granularidade mais fina do processo de venda, correspondendo a **uma linha de encomenda** (OrderLine) registada no sistema operacional.

Nível de Granularidade

Uma linha de produto vendida numa encomenda, incluindo quantidade, preços, descontos e custos de envio alocados.

Chaves

- **Chaves estrangeiras:** DateKey, CustomerKey, ProductKey, CountryKey, SiteKey, CurrencyKey, BoxKey
- **Chaves naturais preservadas como degenerate dimensions:** OrderID, OrderLineID

Medidas Principais

- Quantity
- LineTotal
- Discount
- PromotionDiscount
- ShippingCostAllocated
- TotalLineValue_Local
- TotalLineValue_EUR

Dimensões do Modelo

DimCustomer

Contém informação dos clientes, incluindo país, região geográfica, género, idioma e características relevantes para segmentação. Esta dimensão é gerida com **SCD Tipo 2**, preservando versões históricas dos clientes sempre que ocorrem alterações significativas.

DimDate

Dimensão temporal com **granularidade diária**, organizada por ano, trimestre, mês, dia da semana e nome do dia. É usada para navegar e agregar dados ao longo do tempo.

DimProduto

Reúne os atributos dos produtos e incorpora também a categoria a que pertencem, evitando o uso de snowflake. A dimensão contempla descrição, categoria, género, disponibilidade e informação da caixa associada. Tal como a dimensão de cliente, utiliza **SCD Tipo 2**.

DimCountry

Representa os países associados aos clientes e aos sites, incluindo código, nome, taxa de IVA e indicação se pertence ou não à zona euro.

DimSite

Descreve os diferentes sites da empresa, incluindo nome, URL, país e moeda utilizada nas transações.

DimCurrency

Inclui os códigos e descrições das moedas utilizadas nos vários mercados internacionais. Esta dimensão suporta a conversão monetária que é aplicada durante o processo de ETL.

DimBox

Contém a informação relativa às caixas e embalamentos: dimensões, peso volumétrico e local de armazenamento. É usada para análises associadas ao envio e logística.

Chaves Naturais, Chaves Substitutas e Histórico

Todas as dimensões utilizam **chaves substitutas (surrogate keys)** geradas no Data Mart. As chaves naturais provenientes do sistema operacional são preservadas apenas para referência e auditoria.

As dimensões que necessitam de histórico — nomeadamente Cliente, Produto e Moeda — seguem a abordagem **Slowly Changing Dimensions Tipo 2**, com os campos StartDate, EndDate e IsCurrent, permitindo reconstituir o estado das entidades a qualquer momento no passado.

Estrutura Final do Star Schema

O resultado final é um **Star Schema limpo e direto**, com a FactOrderLine no centro e as dimensões ligadas diretamente a ela, sem estruturas snowflake. Esta abordagem melhora o desempenho das consultas, simplifica a modelação e facilita a criação de relatórios analíticos.

Data Profiling

O processo de *Data Profiling* será realizado com o objetivo de avaliar a qualidade e o estado real dos dados provenientes do sistema operacional (OLTP). Esta análise permitirá identificar problemas estruturais e semânticos que deverão ser tratados na Staging Area antes do carregamento do modelo dimensional. Serão verificados, entre outros aspetos:

Valores Nulos

Serão analisados todos os campos essenciais (como CustomerID, ProductID, OrderDate, Quantity ou Price) de forma a identificar registos incompletos ou com falhas que impeçam o seu carregamento no Data Mart.

Validação de Domínios

Serão verificadas inconsistências em atributos cujo domínio é conhecido, como:

- género,
- país,
- moeda,
- quantidades e preços (não podem ser negativos).

Integridade referencial

Será verificada a coerência entre entidades relacionadas, identificando situações como:

- OrderLines sem encomenda correspondente,
- encomendas com CustomerID inexistente,
- ProductID inexistente na tabela de produtos,
- SiteID sem correspondência na tabela Sites.

Registos que falhem estas verificações serão sinalizados para tratamento na Staging Area.

Deteção de duplicados

Será realizada uma análise de duplicação, com especial atenção aos produtos, uma vez que o enunciado menciona explicitamente que um mesmo produto pode ter sido registado mais do que uma vez com ProductID diferente.

Serão também avaliados possíveis duplicados em clientes (por exemplo, com base no email).

Inconsistências de datas

Serão identificadas datas incorretas, como:

- LastUpdateDate anterior a CreateDate,
- datas futuras incoerentes,
- datas inválidas (ex.: 31/02).

Análise estatística e Outliers

Será efetuada uma análise descritiva de campos numéricos (preços, quantidades, custos), de forma a identificar valores extremos que indiquem possíveis erros de inserção ou discrepâncias relevantes.

Resultado esperado

Os resultados deste processo irão orientar:

- o desenho final das regras de validação,
- a estrutura das tabelas de rejeitados na Staging Area,
- os procedimentos de limpeza e normalização,
- os mecanismos de deduplicação de produtos e clientes.

O *Data Profiling* é, assim, uma etapa fundamental na preparação dos dados para o processo ETL e para garantir que o Data Mart é carregado com informação consistente, completa e adequada para análise.