

ARMDD – Practical Work

Diogo Silva - 1211882

Hugo Ribeiro - 1250520


Introdução.....	2
Arquitetura do Armazém de Dados.....	3
Visão Geral da Arquitetura.....	3
Diagrama Conceptual da Arquitetura.....	4
Requisitos Arquiteturais Específicos.....	4
Modelo Dimensional.....	6
Objetivo do Modelo Dimensional.....	6
Tabelas de Factos.....	7
Dimensões do Modelo.....	8
Data Profiling.....	13
Valores Nulos.....	13
Validação de Domínios.....	13
Integridade referencial.....	13
Detecção de duplicados.....	13
Inconsistências de datas.....	14
Análise estatística e Outliers.....	14
Resultado esperado.....	14
Staging Area (STG).....	14
Objetivos da Staging Area.....	14
Princípios de Estruturação da Staging Area.....	15
Validações e Regras de Qualidade Aplicadas na STG.....	16
Regras de Transformação na Staging.....	18
Fluxo da Staging Area.....	19
Justificação da Staging Area.....	19
Estratégia de Slowly Changing Dimension (SCD).....	20
SCD Tipo 1:.....	20
SCD Tipo 2:.....	20
SCD Tipo 3:.....	20
SCD Tipo 4:.....	20
SCD Tipo 6:.....	20
Logical Map.....	21
DimProduct.....	21
DimSite.....	22
DimDate.....	23

DimCurrency.....	23
DimCustomer.....	23
DimShippment.....	24
DimSize.....	24
FactOrderLine.....	25
FactCurrencyRate.....	25
Análises.....	26
Análise 1.....	26
Análise 2.....	26
Análise 3.....	26
Análise 4.....	26
Análise 5.....	26
Análise 6.....	26
Análise 7.....	27
Análise 9.....	27
Análise 10.....	27

Introdução

Este projeto consiste na concepção e especificação conceptual de um *data mart* destinado à análise histórica das encomendas realizadas na empresa **Plus Orders**, um negócio nacional de comércio eletrónico especializado em moda de luxo, que opera internacionalmente através de diversos **sites por país**.

Todas as encomendas realizadas pelos clientes são centralizadas num sistema operacional (*OLTP*), cujo modelo de dados foi disponibilizado. Este modelo inclui informação sobre clientes, produtos, tamanhos, categorias, países, moedas, sites, encomendas e linhas de encomenda, entre outras entidades.



O propósito desta primeira entrega é documentar a análise dimensional e definir:

- a **arquitetura global** do armazém de dados;
 - o **modelo dimensional** (tabela de factos e dimensões);
 - a **granularidade adotada** e as chaves (naturais e substitutas);
 - as **estruturas da Staging Area**;
 - o **mapeamento** entre sistema operacional → staging → data mart;
 - as **estratégias de Slowly Changing Dimensions (SCD)**;
 - as **regras de limpeza, deduplicação e transformação** necessárias.
-

Arquitetura do Armazém de Dados

Visão Geral da Arquitetura

A arquitetura proposta segue o modelo clássico de **Kimball**, baseado numa abordagem *bottom-up*, recorrendo a uma estrutura de *Data Warehouse* em **três camadas**:

Sistema Operacional (OLTP)

Contém os dados transacionais produzidos pelas operações da empresa. Inclui as tabelas:

- Orders,
- OrdersLines,
- OrdersLinesDetails,
- Products,
- Categories,
- Sizes,
- Boxes,
- Sites,
- SitesInfo,
- Currencies,
- Customers,
- Countries,
- ProductsVideos;

Staging Area (STG)

Camada intermédia onde são carregados os dados brutos extraídos do OLTP.

Funções principais:

- Limpeza de dados;
- Verificação de integridade;
- Tratamento de nulos e duplicados;
- Normalização;


- Detecção de inconsistências;
- Armazenamento de registos rejeitados.

Data Mart (camada analítica – OLAP)

Modelo dimensional em **Star Schema**, otimizado para consultas eficientes, composto por:

- *Fact Table*: **FactOrderLine** e **FactCurrencyRate**
- *Dimensões*: DimCustomer, DimDate, DimProduct, DimSite, DimCurrency, DimSize e DimShipment.

Diagrama Conceptual da Arquitetura



Requisitos Arquiteturais Específicos

Um dos requisitos centrais é o suporte a **cargas incrementais**. Em cada execução do processo ETL, apenas os novos registos são inseridos no Data Mart e os registos previamente carregados são atualizados apenas quando verificadas alterações. Este mecanismo reduz o tempo de processamento, limita o impacto na infraestrutura e assegura uma sincronização contínua entre o sistema operacional e o Data Mart.

A arquitetura contempla também um **tratamento aprofundado da qualidade dos dados**, realizado na Staging Area, garantindo que os dados são consistentes antes de serem integrados no modelo dimensional. Entre as operações aplicadas estão: a eliminação de duplicados, a validação de integridade referencial, a normalização de valores — como nomes de países, moedas e categorias — e a verificação de formatos e domínios válidos. Este processo garante que o Data Mart recebe dados limpos e estruturalmente coerentes.

Outro requisito relevante é o suporte a **conversões monetárias históricas**. Uma vez que os valores das encomendas são registados na moeda local de cada site, o Data Mart deve permitir análises tanto nessa moeda como em EUR, que atua como moeda de uniformização. Para tal, é utilizada uma fact table dedicada às taxas de câmbio, assegurando que cada transação pode ser analisada com base na taxa correspondente à data em que ocorreu.

A solução foi também desenhada para suportar **hierarquias analíticas fundamentais**, tais como:

- Cliente → País → Zona geográfica
- Produto → Categoria
- Site → País do Site
- Tempo → Ano → Trimestre → Mês → Dia

Estas hierarquias são essenciais para permitir análises flexíveis e agregações eficientes, possibilitando navegar entre diferentes níveis de detalhe.

Dado o elevado volume de dados processados diariamente, o Data Mart foi otimizado para suportar **agregações rápidas e eficientes**, nomeadamente em métricas como totais mensais, análises segmentadas por cliente, comparações entre sites ou análises por zona geográfica. A adoção de um modelo dimensional em Star Schema maximiza o desempenho em consultas analíticas e integra-se eficazmente com ferramentas como o Power BI.

A **separação clara entre OLTP e OLAP** constitui outro pilar central da arquitetura. Esta separação reduz o impacto no sistema operacional, assegura um ciclo de processamento limpo e permite que todas as operações de transformação, validação e normalização ocorram na Staging Area, sem comprometer o desempenho das operações transacionais.

Finalmente, a utilização de **Slowly Changing Dimensions (SCD)** — em particular o Tipo 2 para dimensões cujos atributos podem mudar ao longo do tempo — assegura a preservação do histórico necessário para análises temporais rigorosas. Isto aplica-se, por exemplo, à mudança de país de um cliente, à evolução da categoria de um produto ou à eventual alteração de configuração associada a um site.

Em conjunto, estes requisitos e decisões arquiteturais resultam numa solução robusta, consistente e alinhada com as melhores práticas de Data Warehousing, garantindo que a


PlusOrders dispõe de uma plataforma analítica fiável e preparada para as suas necessidades futuras.

Modelo Dimensional

Objetivo do Modelo Dimensional

O modelo dimensional definido tem como objetivo facilitar a análise histórica das encomendas da PlusOrders, permitindo consultas rápidas, organizadas e fáceis de interpretar em ferramentas como o Power BI. Seguindo a metodologia de Kimball, o Data Mart foi estruturado num **Star Schema** centrado em dois processos de negócio:

- (1) o processo de venda (OrderLine) e
- (2) o processo de conversão cambial diária.



Tabelas de Factos

FactOrderLine

FactOrderLine	
FactOrderLineKey 	int
ShipmentKey	int
CustomerKey	int
ProductKey	int
SiteKey	int
SizeKey	int
DateKey	int
CurrencyKey	int
OrderID	int

OrderLineID	int
Quantity	int
LineTotal	money
Discount	money
PromotionDiscount	money
ShippingCostAllocated	money
TotalLineValue_Local	money
TotalLineValue_EUR	money

Representa a granularidade mais fina do processo de venda: uma linha de encomenda individual, contém quantidade, preços, descontos e custos de envio alocados.

Chaves estrangeiras:

- DateKey,
- CustomerKey,
- ProductKey,
- SiteKey,
- SizeKey,
- ShipmentKey,
- CurrencyKey

Chaves naturais preservadas (degenerate dimensions):

- OrderID
- OrderLineID

Medidas principais:

- Quantity,
- LineTotal,

- Discount,
- PromotionDiscount,
- ShippingCostAllocated,
- TotalLineValue_Local,
- TotalLineValue_EUR

FactCurrencyRate

FactCurrencyRate	
FactCurrencyRateKey 	int
DateKey	int
SourceCurrency	int
TargetCurrency	int
ExchangeRate	float

Representa o processo de conversão monetária diária. É carregada a partir da tabela **stg_CurrencyRate** na **Staging Area**.

Chaves estrangeiras:

- DateKey,
- SourceCurrencyKey,
- TargetCurrencyKey

Medida principal:

- ExchangeRate

Dimensões do Modelo

DimCustomer

Contém informação dos clientes, incluindo país, região geográfica, gênero, idioma e características relevantes para segmentação.

DimCustomer	
CustomerKey 🔗	int
CustomerID	int
CountryName	nvarchar(255)
CountryCode	nvarchar(2)
EuroZone	bit
DateOfBirth	nvarchar(255)
Gender	nchar(1)
GeographicRegion	int
Language	nvarchar(2)
VipCustomer	bit
StartDate	date
EndDate	date
IsCurrent	bit

DimDate

Dimensão temporal com **granularidade diária**, organizada por ano, trimestre, mês, dia da semana e nome do dia. É usada para navegar e agregar dados ao longo do tempo.

DimDate	
DateKey 🔗	int
FullDate	date
Year	int
Month	int
MonthName	varchar(20)
Quarter	int
Day	int
DayOfWeek	int
DayName	varchar(20)
WeekOfYear	int
Season	varchar(20)

DimProduct

Reúne os atributos dos produtos e incorpora também a categoria a que pertencem, evitando o uso de snowflake. A dimensão contempla descrição, categoria, gênero, disponibilidade e informação da caixa associada.

A DimProduct inclui também informação da caixa associada, uma vez que a análise ao OLTP confirmou que existe uma relação 1-para-1 entre produto e caixa. Neste cenário, a criação de uma dimensão separada (DimBox) seria redundante e introduziria complexidade desnecessária no modelo. Assim, todos os atributos da caixa foram incorporados diretamente na dimensão de produto, tornando o Star Schema mais simples e eficiente.

DimProduct			
ProductKey 🔗	int		
ProductID	int	BoxWidth	float
Description	nvarchar(255)	BoxVolWeight	float
CategoryName	nvarchar(255)	BoxLocation	float
CategoryGender	nchar(1)	Active	bit
AvailablePortal	bit	ProductVideoID	int
BoxName	nvarchar(255)	StartDate	date
BoxHeight	float	EndDate	date
BoxLength	float	IsCurrent	bit

DimSite

Descreve os diferentes sites da empresa, incluindo nome, URL, país e moeda utilizada nas transações.

DimSite			
SiteKey 🔗	int		
SiteID	int	Phone	bigint
Name	nvarchar(255)	PickupHour	int
IsSite	bit	DailyPickup	bit
SiteURL	nvarchar(255)	TimeZone	nvarchar(255)
SiteName	nvarchar(255)	CountryName	nvarchar(255)
Initials	nvarchar(3)	CountryCode	nvarchar(2)
Currency	nvarchar(3)	EuroZone	bit
StoreContact	nvarchar(255)	StartDate	date
AddressLine1	nvarchar(255)	EndDate	date
AddressLine2	nvarchar(255)	IsCurrent	bit
Zip_City	nvarchar(255)		

DimCurrency

Inclui os códigos e descrições das moedas utilizadas nos vários mercados internacionais. Esta dimensão suporta a conversão monetária que é aplicada durante o processo de ETL.

DimCurrency	
CurrencyKey 🔗	int
CurrencyID	int
CurrencyName	nvarchar(20)
CurrencySymbol	nvarchar(3)

DimSize

Contém a informação relativa ao tamanho e nomes dos produtos separados por país: nome, disponibilidade do produto e tamanho máximo e mínimo.

DimSize	
SizeKey 🔗	int
SizeID	int
Name	nvarchar(255)
FriendlyName	nvarchar(255)
RetailInvisible	bit NN
MinimunSizeAvailable	int NN
MaximunSizeAvailable	int NN

DimShipment

Contém informação relativa aos endereços de envio associados às encomendas, incluindo país, código postal, cidade e demais detalhes logísticos necessários para caracterizar o local de expedição. Esta dimensão permite analisar padrões de entrega e identificar comportamentos geográficos relacionados com os destinos das encomendas.

DimShipment	
ShipmentKey 🔗	int
ShipmentID	int
CountryName	nvarchar(255)
CountryCode	nvarchar(2)
EuroZone	bit
Address	nvarchar(255)
City	nvarchar(255)
State	nvarchar(255)
Zip	float

Chaves Naturais, Chaves Substitutas e Histórico

Todas as dimensões utilizam **chaves substitutas (surrogate keys)** geradas no Data Mart. As chaves naturais provenientes do sistema operacional são preservadas apenas para referência e auditoria.

As dimensões que necessitam de histórico — nomeadamente Cliente, Produto e Site — seguem a abordagem **Slowly Changing Dimensions Tipo 2**, com os campos StartDate, EndDate e IsCurrent, permitindo reconstituir o estado das entidades a qualquer momento no passado.

Estrutura Final do Star Schema

A arquitetura final do Data Mart assume a forma de uma *constellation schema*, composta por duas tabelas de factos: **FactOrderLine**, que representa o processo de vendas, e **FactCurrencyRate**, que suporta o processo de conversão monetária diária.

Cada fact table está ligada diretamente às respetivas dimensões, formando dois Star Schemas independentes mas integrados, sem estruturas do tipo Snowflake. Esta abordagem garante simplicidade, desempenho elevado nas consultas e maior flexibilidade analítica.

Data Profiling

O processo de *Data Profiling* será realizado com o objetivo de avaliar a qualidade e o estado real dos dados provenientes do sistema operacional (OLTP). Esta análise permitirá identificar problemas estruturais e semânticos que deverão ser tratados na Staging Area antes do carregamento do modelo dimensional. Serão verificados, entre outros aspetos:

Valores Nulos

Serão analisados todos os campos essenciais (como CustomerID, ProductID, OrderDate, Quantity ou Price) de forma a identificar registos incompletos ou com falhas que impeçam o seu carregamento no Data Mart.

Validação de Domínios

Serão verificadas inconsistências em atributos cujo domínio é conhecido, como:

- género,
- país,
- moeda,
- quantidades e preços (não podem ser negativos).

Integridade referencial

Será verificada a coerência entre entidades relacionadas, identificando situações como:

- OrderLines sem encomenda correspondente,
- encomendas com CustomerID inexistente,
- ProductID inexistente na tabela de produtos,
- SiteID sem correspondência na tabela Sites.

Registos que falhem estas verificações serão sinalizados para tratamento na Staging Area.

Deteção de duplicados

Será realizada uma análise de duplicação, com especial atenção aos produtos, uma vez que o enunciado menciona explicitamente que um mesmo produto pode ter sido registado mais do que uma vez com ProductID diferente.

Serão também avaliados possíveis duplicados em clientes (por exemplo, com base no email).

Inconsistências de datas

Serão identificadas datas incorretas, como:

- LastUpdateDate anterior a CreateDate,
- datas futuras incoerentes,
- datas inválidas (ex.: 31/02).

Análise estatística e Outliers

Será efetuada uma análise descritiva de campos numéricos (preços, quantidades, custos), de forma a identificar valores extremos que indiquem possíveis erros de inserção ou discrepâncias relevantes.

Resultado esperado

Os resultados deste processo irão orientar:

- o desenho final das regras de validação,
- a estrutura das tabelas de rejeitados na Staging Area,
- os procedimentos de limpeza e normalização,
- os mecanismos de deduplicação de produtos e clientes.

O *Data Profiling* é, assim, uma etapa fundamental na preparação dos dados para o processo ETL e para garantir que o Data Mart é carregado com informação consistente, completa e adequada para análise.

Staging Area (STG)

Objetivos da Staging Area

A **Staging Area** constitui uma camada intermédia fundamental entre o sistema operacional (OLTP) e o Data Mart. A sua função principal é garantir que os dados carregados no modelo dimensional são limpos, consistentes, deduplicados e adequadamente preparados para análise.

Os seus principais objetivos são:

- Receber os dados extraídos do sistema fonte sem transformações complexas.
- Permitir a execução de **data profiling** para avaliação de qualidade e consistência.
- Aplicar validações, limpeza, normalização e processos de deduplicação.
- Identificar registos inválidos ou incompletos antes de chegarem ao Data Mart.
- Preparar os dados para cargas incrementais.
- Manter uma camada isolada que permite auditoria e reproprocessamento em caso de falhas.

Princípios de Estruturação da Staging Area

A Staging Area segue os seguintes princípios:

Estruturas quase idênticas às tabelas OLTP

Cada tabela relevante do sistema operacional tem uma versão equivalente na STG, nomeadamente:

- stg_Orders
- stg_OrdersLines
- stg_OrdersLinesDetails
- stg_Products
- stg_ProductsVideos
- stg_Sites
- stg_SitesInfo
- stg_Boxes
- stg_Sizes
- stg_Categories
- stg_Countries
- stg_Currencies
- stg_CurrencyRates

Ausência de chaves primárias

As tabelas da STG não utilizam chaves primárias, apenas índices técnicos quando necessário, de forma a evitar falhas em cargas sucessivas e simplificar operações de substituição total (*full load*).

Carga sempre *Full Load*

Cada execução do processo ETL apaga e recarrega totalmente as tabelas da STG. Isto garante:

- simplicidade
- reprodutibilidade
- preparação ideal para cargas incrementais no Data Mart

Validações e Regras de Qualidade Aplicadas na STG

Verificações de Nullability

Campos obrigatórios não podem ser nulos, caso contrário esses registos serão rejeitados.

Exemplos:

- OrderID
- CustomerID
- ProductID
- Price
- Quantity
- OrderDate
- SiteID

Verificações de Integridade Referencial

Exemplos:

- Uma linha em OrdersLines deve corresponder a uma encomenda existente em Orders.
- ProductID em OrdersLines deve existir em Products.
- SiteID numa encomenda deve corresponder a um site existente em Sites.
- CountryID deve corresponder a Countries.

Validações de Domínio

Exemplos:

- Quantidade $< 0 \rightarrow$ inválido
- Preço $< 0 \rightarrow$ inválido
- Género não pertence ao conjunto {'M', 'F'}
- Código de moeda não corresponde à tabela stg_Currencies
- País não corresponde à tabela stg_Countries

Tratamento de Datas

Datas inválidas:

- Datas futuras incoerentes com o CreateDate
- LastUpdateDate < CreateDate
- Datas impossíveis (ex.: 31/02)

Deduplicação de Produtos

Como produtos podem existir em duplicado no OLTP com diferentes *ProductID*, foi implementado na Staging Area um processo de identificação e tratamento de duplicados. Entre os diversos métodos analisados, definiu-se a adoção de uma **política conservadora**, privilegiando a integridade dos dados e evitando a eliminação automática de registos.

Para detetar instâncias duplicadas as seguintes medidas foram tomadas:

- **Normalização do nome do produto**
Remoção de acentos, uniformização de caixa (lowercase), remoção de espaços e simplificação de símbolos, permitindo comparações mais consistentes.
- **Comparação de categoria**
Produtos com categoria idêntica são candidatos mais prováveis a duplicação.
- **Comparação de tamanho**
Quando o produto possui tamanho associado, este é utilizado como critério adicional.
- **Comparação aproximada via algoritmos de similaridade**
Utilização do algoritmo *Levenshtein* para identificar nomes muito semelhantes mas não exatamente iguais, reduzindo falsos negativos.

Após serem detetados potenciais duplicados, **não é realizada consolidação automática**. Em vez disso, optou-se por uma abordagem segura e auditável:

- O registo considerado duplicado é carregado na STG **com um indicador adicional (IsPotentialDuplicate = 1)**, permitindo sinalizar este caso explicitamente.
- O produto é mantido na tabela *stg_Products*, **sem alterações ao ProductID**, garantindo que não são feitas associações automáticas que possam ser incorretas.
- A existência de duplicados é **documentada e exposta no relatório de validação da STG**, permitindo a sua análise manual posterior por um responsável de dados ou pela equipa funcional.
- Todo o histórico é preservado, permitindo identificar quantas vezes um produto duplicado apareceu e avaliar o impacto potencial no sistema.

Normalização de Valores

Exemplos:

- “Portugal”, “PT”, “pt”, “Pt” → **Portugal**
- “EUR”, “Euro” → **EUR**
- “uk”, “UK”, “United Kingdom” → **United Kingdom**

Validações para a tabela *stg_CurrencyRates*

A tabela **stg_CurrencyRates** contém taxas de câmbio diárias provenientes de uma fonte externa.

As validações incluem:

- **ExchangeRate** > 0
- **SourceCurrency** e **TargetCurrency** devem existir em **stg_Currencies**
- **DateKey** deve corresponder a uma data válida em **DimDate**
- Não são permitidos valores nulos em **ExchangeRate**, **SourceCurrency**, **TargetCurrency** ou **DateKey**

Regras de Transformação na Staging

Introdução de *surrogate keys*

Por exemplo:

- ClienteSK
- ProdutoSK
- SiteSK
- CurrencySK

As chaves substitutas são geradas apenas quando os dados são carregados nas dimensões.


Preparação da Tabela de Fatos

As tabelas Orders e OrdersLines são integradas e enriquecidas com:

- Dados de clientes
- Dados de produtos
- Dados de sites

- Categorias
- Países
- Conversão para moeda local e EUR
- Data e hora do evento

Fluxo da Staging Area



Justificação da Staging Area

A Staging Area é essencial porque:

- Evita a entrada de dados incorretos no Data Mart.
- Permite reprocessamento rápido em caso de falhas.

- Facilita inspeção e controlo de qualidade.
 - Isola completamente OLTP de OLAP, evitando impacto sobre o sistema operacional.
 - Dá suporte a cargas incrementais consistentes.
 - Permite aplicar regras complexas de normalização, deduplicação e harmonização.
 - Integra dados externos, como taxas de câmbio, de forma controlada e validada.
-

Estratégia de Slowly Changing Dimension (SCD)

Para as dimensões no armazém de dados, foram aplicadas diferentes estratégias de Slowly Changing Dimension (SCD) para manter o histórico dos dados quando necessário:

SCD Tipo 1:

Utilizado em atributos onde o histórico não é relevante e quer-se apenas corrigir valores. Nestes casos, as atualizações são feitas diretamente, substituindo o valor antigo pelo novo.

SCD Tipo 2:

Aplicado a atributos que requerem a manutenção do histórico de mudanças. Isto é feito criando uma linha na tabela de dimensão a cada mudança, permitindo a rastreabilidade de todas as alterações ao longo do tempo.

SCD Tipo 3:

Utilizado para casos em que queremos manter apenas a informação mais recente e a anterior. Nestes casos, mantemos um atributo adicional para armazenar o valor anterior, além do valor atual.

SCD Tipo 4:

Não aplicado explicitamente neste modelo, mas poderia ser utilizado em casos de alto volume de mudanças.

SCD Tipo 6:

Não especificado neste contexto, mas pode ser usado em situações que combinem os requisitos dos tipos 1, 2 e 3.

Logical Map

DimProduct

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimProduct	ProductKey	INT	Dimension	—	—	N/A	N/A	N/A	Surrogate Key
DimProduct	ProductID	INT	Dimension	—	PlusOrders	Products	ProductID	INT	Natural KeyNatural Key for Product in PlusOrders
DimProduct	Description	NVARCHAR(255)	Dimension	1	PlusOrders	Products	Description	NVARCHAR(255)	SELECT UPPER(LEFT(p.Description,1)) + LOWER(SUBSTRING(p.Description,2,LEN(p.Description))) FROM Products p
DimProduct	CategoryName	NVARCHAR(255)	Dimension	1	PlusOrders	Categories	Name	NVARCHAR(255)	SELECT c.Name FROM Products p, Categories c WHERE p.CategoryID = c.CategoryID
DimProduct	CategoryGender	NCHAR(1)	Dimension	1	PlusOrders	Categories	Gender	NCHAR(1)	SELECT c.Gender FROM Products p, Categories c WHERE p.CategoryID = c.CategoryID
DimProduct	AvailablePortal	BIT	Dimension	1	PlusOrders	Products	AvailablePortal	BIT	SELECT p.AvailablePortal FROM Products p
DimProduct	BoxName	NVARCHAR(255)	Dimension	2	PlusOrders	Boxes	BoxName	NVARCHAR(255)	SELECT b.BoxName FROM Products p, Boxes b WHERE p.BoxID = b.BoxID
DimProduct	BoxHeight	FLOAT	Dimension	2	PlusOrders	Boxes	BoxHeight	FLOAT	SELECT b.BoxHeight FROM Products p, Boxes b WHERE p.BoxID = b.BoxID
DimProduct	BoxLength	FLOAT	Dimension	2	PlusOrders	Boxes	BoxLength	FLOAT	SELECT b.BoxLength FROM Products p, Boxes b WHERE p.BoxID = b.BoxID
DimProduct	BoxWidth	FLOAT	Dimension	2	PlusOrders	Boxes	BoxWidth	FLOAT	SELECT b.BoxWidth FROM Products p, Boxes b WHERE p.BoxID = b.BoxID
DimProduct	BoxVolWeight	FLOAT	Dimension	2	PlusOrders	Boxes	VolWeight	FLOAT	SELECT b.VolWeight FROM Products p, Boxes b WHERE p.BoxID = b.BoxID
DimProduct	BoxLocation	NVARCHAR(255)	Dimension	2	PlusOrders	Boxes	Location	NVARCHAR(255)	SELECT b.Location FROM Products p, Boxes b WHERE p.BoxID = b.BoxID
DimProduct	Active	BIT	Dimension	2	PlusOrders	Products	Active	BIT	SELECT CASE WHEN p.Active = 1 THEN 'Active' WHEN p.Active = 0 THEN 'Inactive' ELSE 'Unknown' END FROM Products p
DimProduct	ProductVideoID	INT	Dimension	1	PlusOrders	ProductVideos	ProductVideoID	INT	SELECT v.ProductVideoID FROM Products p, ProductVideos v WHERE p.ProductID = v.ProductID
DimProduct	StartDate	DATE	Dimension	0	PlusOrders	—	—	—	DW_TYPE2_StartDate
DimProduct	EndDate	DATE	Dimension	0	PlusOrders	—	—	—	DW_TYPE2_EndDate
DimProduct	IsCurrent	BIT	Dimension	0	PlusOrders	—	—	—	DW_CurrentFlag

- **ProductID**
Identificador natural do produto no sistema operacional. Não sofre alterações e não necessita de histórico.
- **Description (SCD Tipo 1)**
Alterações na descrição são consideradas correções textuais e não impactam análises, pelo que o valor é simplesmente substituído.
- **CategoryName, CategoryGender (SCD Tipo 1)**
Representam atributos classificativos estáticos. Mudanças não impactam análises históricas.
- **AvailablePortal (SCD Tipo 1)**
Indica se o produto está disponível no portal. Por não ser analiticamente relevante manter versões anteriores, aplica-se SCD1.
- **BoxName, BoxHeight, BoxLength, BoxWidth, BoxVolWeight, BoxLocation (SCD Tipo 2)**
Estas propriedades influenciam custos logísticos e cálculos de peso volumétrico. Para manter uma análise histórica correta, cada alteração gera uma nova linha.
- **Active (SCD Tipo 2)**
Regista se o produto está ou não ativo. Esta informação é relevante para análises temporais e deve manter histórico.
- **ProductVideoID (SCD Tipo 1)**
A ligação a um vídeo promocional é meramente informativa e não exige histórico.
- **StartDate, EndDate, IsCurrent (atributos técnicos SCD2)**
Utilizados para implementar a lógica de histórico.

DimSite

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimSite	SiteKey	INT	Dimension	—	—	—	—	—	Surrogate key
DimSite	SiteID	INT	Dimension	—	PlusOrders	Sites	SiteID	INT	Natural Key for Site in PlusOrders
DimSite	Name	NVARCHAR(255)	Dimension	1	PlusOrders	Sites	Name	NVARCHAR(255)	SELECT UPPER(LEFT(s.Name,1)) + LOWER(SUBSTRING(s.Name,2,LEN(s.Name))) FROM Sites s
DimSite	IsSite	BIT	Dimension	1	PlusOrders	Sites	IsSite	Bit	SELECT s.IsSite FROM Sites s
DimSite	SiteURL	NVARCHAR(255)	Dimension	1	PlusOrders	Sites	SiteURL	NVARCHAR(255)	SELECT s.SiteURL FROM Sites s
DimSite	SiteName	NVARCHAR(255)	Dimension	1	PlusOrders	Sites	SiteName	NVARCHAR(255)	SELECT UPPER(LEFT(s.SiteName,1)) + LOWER(SUBSTRING(s.SiteName,2,LEN(s.SiteName))) FROM Sites s
DimSite	Initials	NVARCHAR(3)	Dimension	1	PlusOrders	Sites	Initials	NVARCHAR(3)	SELECT UPPER(s.Initials) FROM Sites s
DimSite	Currency	NVARCHAR(3)	Dimension	1	PlusOrders	Sites	Currency	NVARCHAR(3)	SELECT s.Currency FROM Sites s
DimSite	StoreContact	NVARCHAR(255)	Dimension	2	PlusOrders	SitesInfo	StoreContact	NVARCHAR(255)	SELECT si.StoreContact FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	AddressLine1	NVARCHAR(255)	Dimension	2	PlusOrders	SitesInfo	AddressLine1	NVARCHAR(255)	SELECT si.AddressLine1 FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	AddressLine2	NVARCHAR(255)	Dimension	2	PlusOrders	SitesInfo	AddressLine2	NVARCHAR(255)	SELECT si.AddressLine2 FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	Zip_City	NVARCHAR(255)	Dimension	2	PlusOrders	SitesInfo	Zip_City	NVARCHAR(255)	SELECT si.Zip_City FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	Phone	BIGINT	Dimension	2	PlusOrders	SitesInfo	Phone	BIGINT	SELECT si.Phone FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	PickupHour	INT	Dimension	2	PlusOrders	SitesInfo	PickupHour	INT	SELECT si.PickupHour FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	DailyPickup	BIT	Dimension	2	PlusOrders	SitesInfo	DailyPickup	BIT	SELECT si.DailyPickup FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	TimeZone	NVARCHAR(255)	Dimension	2	PlusOrders	SitesInfo	TimeZone	NVARCHAR(255)	SELECT si.TimeZone FROM Sites s, SitesInfo si WHERE s.SiteID = si.SiteID
DimSite	CountryName	NVARCHAR	Dimension	2	PlusOrders	Countries	Name	NVARCHAR	SELECT c.Name FROM Sites s, Countries c WHERE s.CountryID = c.CountryID
DimSite	CountryCode	NVARCHAR(5)	Dimension	2	PlusOrders	Countries	Code	NVARCHAR	SELECT c.Code FROM Sites s, Countries c WHERE s.CountryID = c.CountryID
DimSite	EuroZone	BIT	Dimension	2	PlusOrders	Countries	EuroZone	BIT	SELECT c.EuroZone FROM Sites s, Countries c WHERE s.CountryID = c.CountryID

- **SiteID**
Identificador natural da loja. Não muda.
- **Name, SiteURL, SiteName, Initials, Currency (SCD Tipo 1)**
Atributos estáveis cujas alterações não necessitam de histórico.
- **IsSite (SCD Tipo 1)**
Informação estável que não justifica histórico.
- **StoreContact (SCD Tipo 2)**
Mudanças de contacto são relevantes para auditorias e histórico operacional.
- **AddressLine1, AddressLine2, Zip_City (SCD Tipo 2)**
Mudanças de morada e localização precisam de histórico, dado o impacto em logística e análises geográficas.
- **Phone (SCD Tipo 2)**
Embora seja um contacto, no negócio PlusOrders o número está associado ao funcionamento do site, e preserva-se o histórico.
- **PickupHour, DailyPickup, TimeZone (SCD Tipo 2)**
Estas propriedades afetam janelas logísticas e operações, justificando rastreabilidade.
- **CountryName, CountryCode, EuroZone (SCD Tipo 2)**
Alterações de país impactam análises fiscais e geográficas.

DimDate

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimDate	DateKey	INT	Dimension	—	—	—	—	—	INT de formato YYYYMMDD a partir de FullDate
DimDate	FullDate	DATE	Dimension	0	—	—	—	—	Calendário gerado por rotina no DW
DimDate	Year	INT	Dimension	0	—	—	—	—	YEAR(FullDate)
DimDate	Month	INT	Dimension	0	—	—	—	—	MONTH(FullDate)
DimDate	MonthName	NVARCHAR(20)	Dimension	0	—	—	—	—	DATENAME(MONTH, FullDate)
DimDate	Quarter	INT	Dimension	0	—	—	—	—	DATEPART(QUARTER, FullDate)
DimDate	Day	INT	Dimension	0	—	—	—	—	DAY(FullDate)
DimDate	DayOfWeek	INT	Dimension	0	—	—	—	—	DATEPART(WEEKDAY, FullDate)
DimDate	DayName	NVARCHAR(20)	Dimension	0	—	—	—	—	DATENAME(WEEKDAY, FullDate)

A DimDate é tratada como uma dimensão de **SCD Tipo 0**, uma vez que os seus valores são imutáveis. Atributos temporais não sofrem alterações ao longo do tempo e, por definição, não existe histórico a registar nem necessidade de capturar versões anteriores. Assim, todos os atributos da dimensão mantêm sempre o mesmo valor, e não são aplicados mecanismos de SCD Tipo 1 ou Tipo 2.

DimCurrency

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimCurrency	CurrencyKey	INT	Dimension	—	—	—	—	—	Surrogate key
DimCurrency	CurrencyID	NVARCHAR(3)	Dimension	—	PlusOrders	Currencies	CurrencyID	NVARCHAR(3)	SELECT c.CurrencyID FROM Currencies c
DimCurrency	CurrencyName	NVARCHAR(20)	Dimension	1	PlusOrders	Currencies	CurrencyName	NVARCHAR(20)	SELECT UPPER(LEFT(c.CurrencyName,1)) + LOWER(SUBSTRING(c.CurrencyName,2,LEN(c.CurrencyName))) FROM Currencies c
DimCurrency	CurrencySymbol	NVARCHAR(3)	Dimension	1	PlusOrders	Currencies	CurrencySymbol	NVARCHAR(3)	SELECT c.CurrencySymbol FROM Currencies c

- **CurrencyID**
Identificador da moeda, estável.
- **CurrencyName, CurrencySymbol (SCD Tipo 1)**
Alterações são raras e não têm impacto analítico.

DimCustomer

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimCustomer	CustomerKey	INT	Dimension	—	—	—	—	—	Surrogate key
DimCustomer	CustomerID	INT	Dimension	—	PlusOrders	Customers	CustomerID	INT	SELECT c.CustomerID FROM Customers c
DimCustomer	CountryName	NVARCHAR(255)	Dimension	2	PlusOrders	Countries	CountryName	NVARCHAR(255)	SELECT co.CountryName FROM Customers c, Countries co WHERE c.CountryCode = co.CountryCode
DimCustomer	CountryCode	NVARCHAR(2)	Dimension	2	PlusOrders	Countries	CountryCode	NVARCHAR(2)	SELECT co.CountryCode FROM Customers c, Countries co WHERE c.CountryCode = co.CountryCode
DimCustomer	EuroZone	BIT	Dimension	2	PlusOrders	Countries	EuroZone	BIT	SELECT co.EuroZone FROM Customers c, Countries co WHERE c.CountryCode = co.CountryCode
DimCustomer	DateOfBirth	NVARCHAR(255)	Dimension	0	PlusOrders	Customers	DateOfBirth	NVARCHAR(255)	SELECT c.DateOfBirth FROM Customers c
DimCustomer	Gender	NVARCHAR(1)	Dimension	1	PlusOrders	Customers	Gender	NVARCHAR(1)	SELECT c.Gender FROM Customers c
DimCustomer	GeographicRegion	INT	Dimension	1	PlusOrders	Customers	GeographicRegion	INT	SELECT c.GeographicRegion FROM Customers c
DimCustomer	Language	NVARCHAR(2)	Dimension	1	PlusOrders	Customers	Language	NVARCHAR(2)	SELECT c.Language FROM Customers c
DimCustomer	VipCustomer	BIT	Dimension	1	PlusOrders	Customers	VipCustomer	BIT	SELECT c.VipCustomer FROM Customers c
DimCustomer	StartDate	DATE	Dimension	0	—	—	—	—	DW_TYPE2_StartDate
DimCustomer	EndDate	DATE	Dimension	0	—	—	—	—	DW_TYPE2_EndDate
DimCustomer	IsCurrent	BIT	Dimension	0	—	—	—	—	DW_CurrentFlag

- **CustomerID**
Identificador fixo e imutável.
- **CountryName, CountryCode, EuroZone (SCD Tipo 2)**
Mudanças de país têm implicações fiscais e logísticas; por isso mantêm histórico.
- **DateOfBirth (SCD Tipo 0)**
Dado imutável.
- **Gender, GeographicRegion, Language, VipCustomer (SCD Tipo 1)**
Mudanças nestes atributos não requerem histórico pois não estão associadas a análises temporais críticas.
- **StartDate, EndDate, IsCurrent (técnicos – SCD0)**

DimShippment

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimShippment	CountryName	NVARCHAR(255)	Dimension	2	PlusOrders	Countries	Name	NVARCHAR(255)	SELECT c.Name FROM Orders o, Countries c WHERE o.CountryCode = c.CountryCode
DimShippment	CountryCode	NVARCHAR(2)	Dimension	2	PlusOrders	Countries	Code	NVARCHAR(2)	SELECT o.CountryCode FROM Orders o
DimShippment	EuroZone	BIT	Dimension	2	PlusOrders	Countries	EuroZone	BIT	SELECT c.EuroZone FROM Orders o, Countries c WHERE o.CountryCode = c.CountryCode
DimShippment	Address	NVARCHAR(255)	Dimension	2	PlusOrders	Orders	Address	NVARCHAR(255)	SELECT o.Address FROM Orders o
DimShippment	City	NVARCHAR(255)	Dimension	2	PlusOrders	Orders	City	NVARCHAR(255)	SELECT o.City FROM Orders o
DimShippment	State	NVARCHAR(255)	Dimension	2	PlusOrders	Orders	State	NVARCHAR(255)	SELECT o.State FROM Orders o
DimShippment	Zip	NVARCHAR(20)	Dimension	2	PlusOrders	Orders	Zip	FLOAT	SELECT CAST(o.Zip AS NVARCHAR(20)) FROM Orders o

- **CountryName, CountryCode, EuroZone (SCD Tipo 2)**
A localização de envio define regras fiscais e logísticas. O histórico é necessário.
- **Address, City, State, Zip (SCD Tipo 2)**
A morada de envio pode mudar ao longo do tempo e tem impacto direto em custos e operações. O histórico deve ser preservado.

DimSize

Target					Source				Transformation
Table Name	Column Name	Data Type	Table Type	SCD Type	Database Name	Table Name	Column Name	Data Type	
DimSize	SizeKey	INT	Dimension	—	—	—	—	—	Surrogate key
DimSize	SizeID	INT	Dimension	—	PlusOrders	Sizes	SizeID	INT	SELECT s.SizeID FROM Sizes s
DimSize	Name	NVARCHAR(255)	Dimension	1	PlusOrders	Sizes	Name	NVARCHAR(255)	SELECT UPPER(LEFT(s.Name,1)) + LOWER(SUBSTRING(s.Name,2,LEN(s.Name))) FROM Sizes s
DimSize	FriendlyName	NVARCHAR(255)	Dimension	1	PlusOrders	Sizes	FriendlyName	NVARCHAR(255)	SELECT UPPER(LEFT(s.FriendlyName,1)) + LOWER(SUBSTRING(s.FriendlyName,2,LEN(s.FriendlyName))) FROM Sizes s
DimSize	RetailInvisible	BIT	Dimension	1	PlusOrders	Sizes	RetailInvisible	BIT	SELECT s.RetailInvisible FROM Sizes s
DimSize	MinimumSizeAvailable	INT	Dimension	1	PlusOrders	Sizes	MinimumSizeAvailable	INT	SELECT s.MinimumSizeAvailable FROM Sizes s
DimSize	MaximumSizeAvailable	INT	Dimension	1	PlusOrders	Sizes	MaximumSizeAvailable	INT	SELECT s.MaximumSizeAvailable FROM Sizes s

- **SizeID**
Identificador do tamanho, estável.
- **Name, FriendlyName, RetailInvisible, MinimumSizeAvailable, MaximumSizeAvailable (SCD Tipo 1)**
Alterações nestes atributos são administrativas e não necessitam de histórico.

linha representa o estado histórico fechado de uma taxa, no momento em que foi carregada no Data Warehouse.

Análises

Análise 1

Valores totais das encomendas efetuadas no primeiro trimestre de 2022, detalhados pelo sexo do cliente e pela categoria do produto.

Análise 2

Valores totais dos custos de expedição (frete) despendidos no transporte dos produtos durante o mês de fevereiro de 2022, detalhados pelo país de expedição e por categoria de produto.

Análise 3

Valores totais e respetivas quantidades referentes aos produtos encomendados no primeiro semestre de 2023, detalhados por site e por zona geográfica do cliente.

Análise 4

Valores das encomendas efetuadas sem e com custos de expedição durante o ano de 2023, detalhados pelos países para onde foram enviados que pertencem unicamente à zona Euro.

Análise 5

Valores totais e respetivas quantidades encomendadas efetuadas no último dia de cada mês do ano de 2022, detalhados por categoria do produto, com possibilidade de análise detalhada (i.e., drill down) ao nível individual do produto.

Análise 6

Valores totais dos custos de expedição referentes às encomendas realizadas na 6ª semana do ano de 2023, detalhados por caixa de expedição e por país de envio, com possibilidade de análise detalhada (i.e., drill down) ao nível do local de expedição.

Análise 7

Valores totais das encomendas e respectivas quantidades, efetuadas no 2º quadrimestre de 2023, detalhados pela zona geográfica do cliente e por produto, com possibilidade de análise agregada (i.e., roll up) ao nível da categoria do produto.

Análise 8

Valores totais das encomendas (em libras) efetuadas durante a primavera e verão de 2022, detalhados por país e sexo do cliente, apenas para os clientes cuja moeda seja libras (GBP).

Análise 9

Valores totais dos custos de expedição por cliente, com possibilidade de análise agregada (i.e., roll up) ao nível do país do cliente, e por mês do ano de 2023, com possibilidade de análise agregada (i.e., roll up) ao nível do trimestre, semestre ou ano, unicamente para os produtos que pertençam às categorias “Clothing”, “Shoes” e “Accessories”.

Análise 10

Valores totais e respectivas quantidades encomendadas ao fim-de-semana, nos anos de 2022 e 2023, dos produtos cujo tamanho máximo disponível seja 52, detalhados pelo país do site onde foi realizada a encomenda, com possibilidade de análise detalhada (i.e., drill down) ao nível do próprio site, e por tipo de serviço UPS, com possibilidade de análise detalhada (i.e., drill down) ao nível do próprio site.